

Detección de Ondas Gravitacionales Anómalas con Machine Learning

Franco Cerino

23 de enero de 2025


1. Introducción y problemática a resolver
2. Dataset
3. Aprendizaje Supervisado
4. Aprendizaje No Supervisado
5. Conclusiones

Introducción

- La detección de ondas gravitacionales (GW) en observatorios como LIGO y Virgo es un desafío, debido a que el ruido es dominante en las mediciones.
- Las detecciones se realizan con el método Matched-filtering (MF).
- En MF se utilizan señales previamente modeladas, como de sistemas binarios de agujeros negros y estrellas de neutrones.
- MF compara los datos medidos con modelos teóricos de GW. Si hay una similitud grande, se considera que se ha detectado una GW.
- Existe la problemática que con este método pueden pasar por alto GW no lo suficientemente bien modeladas, como de púlsares, supernovas, fuentes no conocidas o con estocasticidad.
- A este tipo de ondas se las denomina anómalas.

Introducción

- Son necesarias nuevas técnicas para identificar fuentes donde las GW no están modeladas. Encontrar estas anomalías presentan una oportunidad para la innovación en el área de detección de GW.
- Existe un Challenge de ML en curso denominado "Detecting Anomalous Gravitational Wave Signals".



The poster features a circular image on the left showing two black holes in the process of merging, with vibrant purple and blue gravitational wave ripples emanating from them. To the right of the image, the title "NSF HDR A3D3: DETECTING ANOMALOUS GRAVITATIONAL WAVE SIGNALS" is written in large, bold, dark blue capital letters. Below the title, a red rectangular banner contains a gold trophy icon and the text "A pool of 6000 USD and additional awards". At the bottom, smaller text provides organizational details: "ORGANIZED BY: A3d3hdr", "CURRENT PHASE ENDS: January 16, 2025 At 9:00 PM GMT-3", "CURRENT SERVER TIME: December 16, 2024 At 8:27 PM GMT-3", and a Docker image link: "Docker image: ghcr.io/a3d3-institute/hdr-image:latest".

NSF HDR A3D3: DETECTING ANOMALOUS GRAVITATIONAL WAVE SIGNALS

 A pool of 6000 USD and additional awards

ORGANIZED BY: A3d3hdr
CURRENT PHASE ENDS: January 16, 2025 At 9:00 PM GMT-3
CURRENT SERVER TIME: December 16, 2024 At 8:27 PM GMT-3
Docker image: ghcr.io/a3d3-institute/hdr-image:latest


- Se aborda este problema de detección con Machine Learning (ML), ya que es una metodología efectiva para identificar patrones complejos en grandes volúmenes de datos.

Objetivos del trabajo


- Exploración de modelos supervisados y no supervisados para la detección de GW anómalas.
- Se comenzó con modelos simples para establecer un baseline.
- Luego se utilizó modelos más expresivos para mejorar los resultados.
- Evaluación de modelos:
 1. Con datos de clases utilizadas para entrenar (lo usual en ML).
 2. Con una clase de GW no conocida por el modelo, para ver la capacidad de detección de GW anómalas.

Dataset


- Tipos de datos:
 - **Background:** Ruido de observación O3a de LIGO.
 - **Ondas de agujeros negros binarios (BBH):** Señales simuladas de BBH son inyectadas en el ruido.
 - **Ondas seno-gaussianas (SG):** Ondas sintéticas que representan potenciales GW que no están en categorías bien entendidas como BBH. También embebidas en ruido.
- Dimensiones de cada tipo: (100000, 200, 2). La última dimensión corresponde a los interferómetros de LIGO en Hanford y Livingston.



BBH GW.



Background.



SG GW.

Aprendizaje Supervisado


- Se tiene datos etiquetados, por lo tanto podemos usar ML Supervisado.
- Se entrenó los modelos para clasificar entre ruido y ondas BBH.
- Se testeó los modelos con ondas SG, para ver la accuracy sobre ondas no conocidas.

Modelo	Accuracy	Accuracy en ondas SG
KNN	0.86	0.22
KNN en cada detector	0.93	0.10
Random Forest	0.88	0.05
Random Forest en cada detector	0.83	0.01
Red convolucional 1D	0.97	0.08


- Para detección de ondas SG baja considerablemente el accuracy. Se las clasifica como ruido.

Aprendizaje Supervisado


- Clasificación con You Only Look Once (YOLO):
 - Modelo basado en CNN.
 - La versión 11 es el estado del arte en clasificación.
 - Para entrenar YOLO, se obtiene un espectrograma para cada señal.



BBH GW.



Background.




SG GW.

Modelo	Accuracy en ruido y BBH	Accuracy en ondas SG
YOLO	0.96	0.58

- Se obtiene una mejora para detectar ondas SG.

Aprendizaje No Supervisado

- Los modelos supervisados suelen no dar garantía de identificar anomalías.
- Se busca entrenar modelos no supervisados únicamente con ruido para poder identificar desviaciones o anomalías del mismo.
- Se utilizaron Transformers y Autoencoders.
- Procesan cada serie temporal y luego intentan reconstruirla.
- Se busca diferenciar el Error Cuadrático Medio (MSE) de reconstrucción entre ruido y GW.




Arquitectura de un Autoencoder para aprender el ruido.

Aprendizaje No Supervisado

- Se realizó búsqueda de hiperparámetros con la librería Optuna.
- Se buscó entender el MSE de reconstrucción del ruido para identificar cuando un MSE representa una anomalía.

Modelo	Accuracy en ruido y BBH	Accuracy en ondas SG
Transformer	0.68	0.64
Autoencoder	0.53	0.57



Histogramas del MSE de reconstrucción de un Autoencoder para cada tipo de señal.

Conclusiones

- En este trabajo no se buscó modelar los datos que se quiere encontrar, sino entender los datos conocidos y cuales desviaciones se pueden considerar como anomalías.
- Datos utilizados para detectar GW: ruido, ondas BBH y ondas SG.
- Se utilizaron ondas SG únicamente para testear, representando ondas gravitacionales anómalas.
- Los modelos supervisados tuvieron un accuracy alto para distinguir entre ondas BBH y ruido, pero en general no para ondas SG.
- Se ha utilizado modelos no supervisados con la idea de aprender únicamente el ruido para poder detectar desviaciones significativas.
- Para detección de anomalías los modelos no supervisados y YOLO fueron los mejores modelos, con accuracy entre 0.57 y 0.64.
- Si se toma el accuracy a lo largo de todas las clases, el de mejor performance fue YOLO.

Gracias!