

Búsqueda de hiperparámetros optimizada con la librería Optuna

Franco Cerino

Búsqueda de Hiperparámetros

- Los hiperparámetros (HP) son parámetros de configuración de un modelo de Machine Learning (ML) que deben ser establecidos antes del proceso de entrenamiento.
- Para evaluar el impacto de cada combinación de hiperparámetros sobre el rendimiento de un modelo, es necesario entrenar uno para cada configuración.

Métodos standard

- Random Search y Grid Search.
- Problemáticas:
 - Ineficientes computacionalmente hablando, no utilizan información de las sucesivas evaluaciones para obtener mejores modelos.
 - Si el espacio de combinaciones de HP suele ser muy amplio y/o los modelos son muy costosos de entrenar, puede no ser viable una búsqueda exhaustiva.

Búsqueda de Hiperparámetros.

- **Sequential Model-Based Optimization (SMBO):**

Es un método secuencial, donde en cada iteración:

1. Se entrena un modelo de ML con hiperparámetros x y se obtiene el resultado para una función de costo $f(x)$.
 2. Se utilizan los pares $(x, f(x))$ obtenidos para estimar cual es el valor de x que minimiza $f(x)$.
- En Python la librería Optuna permite realizar una optimización eficiente de hiperparámetros con SMBO, utilizando el método Tree Parzen Estimator (TPE).
 - TPE permite optimización sobre hiperparámetros continuos, discretos y categóricos.
 - Optuna permite optimización multiobjetivo.
 - Documentación de Optuna: optuna.readthedocs.io


Tree Parzen Estimator (TPE)

- En cada iteración, a partir de $\{(x_i, f(x_i))\}$ se ordena a los hiperparámetros según la performance sobre la función de costo $f(x)$ y se construye dos distribuciones:
 - $l(x)$ para los mejores x_i .
 - $g(x)$ para los peores x_i .
 - Para construir cada una, en la ubicación de cada hiperparámetro se ubica una curva Gaussiana. La distribución resultante es una suma de Gaussianas normalizada.



Tree Parzen Estimator (TPE)

- La combinación de hiperparámetros x_i para entrenar el algoritmo en la próxima iteración será la que maximice el cociente $l(x)/g(x)$.



Tree Parzen Estimator (TPE)

- (Bergstra, 2011): "We chose to use this criterion in our work because it is intuitive, and has been shown to work well in a variety of settings"

El costo computacional de TPE en Optuna es de $O(dn \log n)$, donde:

- d el numero de dimensiones del espacio de búsqueda.
- n el número de iteración o trial de TPE.

Tree Parzen Estimator (TPE)

- $f(x) = y$ es la función de costo que queremos optimizar.
- $f(x^*) = y^*$ es un valor de referencia que se quiere mejorar.

La idea es que la próxima combinación de hiperparámetros x cumpla:

$$f(x^*) - f(x) > 0 \quad (1)$$

Se define una función de mejora o improvement:

$$l(x) = \max(f(x^*) - f(x), 0) \quad (2)$$

No se conoce a $f(x)$ por completo. Por lo tanto se la toma como una variable aleatoria y se busca el x que maximice el valor esperado de $l(x)$.

$$El(x) = \mathbb{E}[\max(f(x^*) - f(x), 0)] \quad (3)$$

Tree Parzen Estimator (TPE)

$$\text{EI}(x) = \int_{-\infty}^{\infty} \max(y^* - y, 0) p(y | x) dy \quad (4)$$

$$= \int_{-\infty}^{y^*} (y^* - y) \frac{p(x | y) p(y)}{p(x)} dy \quad (5)$$

La integral se resuelve utilizando:

$$p(x | y) = \begin{cases} l(x) & \text{si } y < y^* \\ g(x) & \text{si } y \geq y^* \end{cases} \quad (6)$$

Donde y^* es un cuantil γ de los valores observados, ie: $p(y < y^*) = \gamma$.

Se obtiene:

$$\text{EI}(x) \propto \left(\gamma + (1 - \gamma) \frac{g(x)}{l(x)} \right)^{-1} \quad (7)$$

Por lo tanto se busca un x que maximice el cociente $l(x)/g(x)$.