

Modelos sustitutos de ondas gravitacionales con partición de dominio

Franco Cerino (CONICET, FaMAF).


Director: Manuel Tiglio (CONICET, FaMAF).

Organización de la presentación

1. Introducción al estudio de ondas gravitacionales (GW).
2. Problemáticas en la predicción de GW.
3. Marco teórico: Modelos sustitutos y hp-greedy.
4. Diseño de la librería scikit-reducedmodel.
5. Metodologías y resultados.
6. Conclusiones.

Introducción al estudio de ondas gravitacionales


- En el año 2015, por primera vez interferómetros de LIGO detectan directamente ondas gravitacionales (GW), coincidiendo con una GW obtenida con la Teoría de la Relatividad General.




- Permiten el estudio directo de la Teoría de la Relatividad General.
- Hasta el día de hoy se ha detectado 218 señales de GW, la mayoría de ellas procedentes de sistemas binarios de agujeros negros.
- Se espera aumento acelerado del número de mediciones.
- La detección y el posterior estudio de GW se realiza comparando las mediciones con modelos de GW.

Introducción al estudio de ondas gravitacionales

- Constatando que se ha medido una GW:




- Las GW que estudiamos se denominan Inspiral-Merger-Ringdown:




Introducción al estudio de ondas gravitacionales

- El modelado de GW es esencial para diversos estudios:




Catálogos de GW.



Estimación de parámetros.



Estudios poblacionales.




Tests de la Relatividad General.

Problemáticas en la predicción de GW

- Los estudios de estimación de parámetros pueden requerir de 10^6 a 10^8 estimaciones secuenciales de GW.
- El método fidedigno para obtener GW es a través de las Ecuaciones de Einstein utilizando Relatividad Numérica (RN).
- Obtener una GW utilizando RN puede tardar meses utilizando supercomputadoras.
- Los modelos sustitutos de GW permiten afrontar esta problemática:
 - Se entrenan con GW fidedignas y computacionalmente costosas.
 - Expresiones que se evalúan en decenas de segundos o menos.
 - En muchos casos sin pérdida de precisión con respecto a RN.

Problemáticas en la predicción de GW

- Para los próximos años se esperan mejoras en la sensibilidad de los interferómetros, implicando:
 - Aumento significativo de detecciones.
 - Necesidad de modelos de GW más precisos en órdenes de magnitud.



- Nos enfocamos en optimizar modelos sustitutos de GW para afrontar problemáticas en precisión y tiempo de predicción.


Construcción de modelos sustitutos

La construcción de un modelo sustituto conlleva tres pasos secuenciales:

1. Encontrar una Base Reducida del espacio de soluciones.
 2. Construir un Interpolante Empírico.
 3. Realizar regresiones para predecir nuevas soluciones.
- } Compresión
- } Aprendizaje


Modelos sustitutos: 1) Base Reducida (RB)

- GW de entrenamiento fidedignas $\mathcal{T} := \{h_{\lambda_i}(t)\}_{i=1}^m$
- Para GW, $\lambda = (q, \vec{\chi}_1, \vec{\chi}_2)$.
- RB: Base de baja dimensionalidad, representativa de $\mathcal{T}$.
- Se utiliza un algoritmo Greedy:
 1. En cada iteración, el $h_{\lambda_i} \in \mathcal{T}$ peor representado se añade a la RB.
 2. Finalización:
 - $\sigma_n = \|h_{\lambda_i} - \mathcal{P}_n h_{\lambda_i}\|^2 \leq \epsilon \quad \forall \lambda_i \in \mathcal{T}$.
 - $\dim(RB) = n_{max}$.
- Compresión de información cuasi-óptima. $\sigma_n \lesssim e^{-\alpha n}$



Modelos sustitutos: 1) RB con partición de dominio.

- Se modela subespacios más simples particionando el espacio de parámetros de forma recursiva.




- La estructura de árbol permite predicciones rápidas.
- Partición adaptativa con el método hp-greedy:
 - Construcción de una RB.
 - Se particiona si la RB no cumple tolerancia ϵ con $\dim(RB) \leq n_{max}$.
 - Repetir 1. y 2.
 - Finalización: tolerancia ϵ o profundidad l_{max} .

Modelos sustitutos: 2) Método de interpolación empírica.

- Usando una RB $\{e_i(t)\}_{i=1}^n$:
 - Con conjunto óptimo de *tiempos empíricos* $\{T_i\}_{i=1}^n$ para interpolar.
 - Se construye una expresión para un *interpolante empírico*:


$$\mathcal{I}[h_\lambda](t) := \sum_{i=1}^n B_i(t) h_\lambda(T_i).$$

- $B_i(t)$ en función de RB y *tiempos empíricos*.



Modelos sustitutos: 3) Regresiones.

- Para evaluar $\mathcal{I}[h_\lambda](t) \forall \lambda$, se necesita $\{h_\lambda(T_i)\}_{i=1}^n \forall \lambda$.
- Para cada T_i se conoce $h_{\lambda_j}(T_i)$, $\lambda_j \in \mathcal{T}$.
- Para cada T_i , se entrena un modelo de regresión a lo largo del espacio de parámetros para obtener $h_\lambda^{ML}(T_i), \forall \lambda$.




Modelos sustitutos: Realizando predicciones.

- Usando las regresiones entrenadas $\{h_\lambda^{\text{ML}}(T_i)\}_{i=1}^n$, una predicción está dada por:

$$h_\lambda^{\text{surr}}(t) := \mathcal{I}[h_\lambda](t) = \sum_{i=1}^n B_i(t) h_\lambda^{\text{ML}}(T_i).$$

- Cota para el error de $h_\lambda^{\text{surr}}(t)$:

$$\Delta t \sum_{i=1}^L |h_\lambda(t_i) - h_\lambda^{\text{surr}}(t_i)|^2 \leq \Lambda_n \sigma_n + \Lambda_n \Delta t \sum_{i=1}^n |h_\lambda(T_i) - h_\lambda^{\text{surr}}(T_i)|^2$$



Diseño de software: scikit-reducedmodel


Diseño de software: scikit-reducedmodel

- Se creó la librería de modelos sustitutos *scikit-reducedmodel*.
- Implementa todas las etapas de los modelos sustitutos.
- Implementa hp-greedy.
- Da libertad de elegir y optimizar regresiones.
- Sigue principios de *Scikit-Learn*:
 - Open-source.
 - Disponible públicamente.
 - Modelos personalizados.
 - Interfaz eficiente y documentada.
 - Facilidad para usuarios no expertos en aprendizaje automático.



Diseño de software: scikit-reducedmodel

- Clases: `reducedbasis`, `empiricalinterpolation` y `surrogate`.
- Se mantiene la interfaz de `scikit-learn`:
 - Las clases son estimadores, utilizan el método `fit` para entrenarse.
 - Utilizan el método `transform` o `predict`, según corresponda, para obtener representaciones de funciones.
- La modularización permite estudios específicos con el método de base reducida o el método de interpolación empírica.
- Se obtiene un modelo sustituto al componer instancias de las clases.



Diseño de software: scikit-reducedmodel

- Función `mk surrogate`: utiliza una serie de clases y toma toda la responsabilidad para construir una instancia.

```
>>> from skreducedmodel.mk surrogate import mk surrogate
>>> surrogate = mk surrogate(
>>>     training_set=waveforms_train,
>>>     parameters=parameters_train,
>>>     physical_points=times
>>>     greedy_tol=1e-16,
>>>     lmax=2,
>>>     nmax=10
>>>     regression_model=MLPRegressor
>>>     regression_hyperparameters= {
>>>         'hidden_layer_sizes': (20, 20),
>>>         'activation': 'tanh',
>>>         'learning_rate_init': 0.015,
>>>     }
>>> )
>>> waveform_prediction = surrogate.predict(parameter_test)
```

- Instalación: `pip install scikit-reducedmodel`



Metodologías y Resultados

Trabajos realizados

- Bases Reducidas:
 - ◇ Base reducida global vs hp-greedy.
 - ◇ Optimizacion de hiperparámetros de hp-greedy.
- Etapa de regresiones:
 - ◇ Eleccion de regresiones con AutoML.
- Optimizacion de Bases reducidas y regresiones:
 - ◇ Optimizacion Multi Objetivo de modelos sustitutos.



Las GW de entrenamienyo y testeo se generaron a partir de otros modelos sustitutos. En general se ha utilizado el modelo sustituto NRHybSur3dq8:


- Inspiral, merger y ringdown: $[-3000, 150] M$, donde en $t = 0$ es el merger.
- Se considera el modo dominante $\ell = m = 2$.
- Cocientes de masas $1 \leq q \leq 8$ y spines adimensionales alineados con el momento angular orbital del sistema, donde $|\chi_{iz}| \leq 0,8$.

Estudiamos tres casos:

- 1D: Sin espín. El único parámetro libre es $q = m_1/m_2$, debido a la invariancia de escala de la Relatividad General.
- 2D: Se añaden dos espines alineados con la misma magnitud al caso 1D, $\chi_{1z} = \chi_{2z}$.
- 3D: Se permite que los dos espines varíen de forma independiente, $\chi_{1z} \neq \chi_{2z}$.

Base reducida global vs hp-greedy



- Convergencia de hp-greedy con en comparación de una Base Reducida global para casos 1D, 2D y 3D, de izquierda a derecha y de arriba hacia abajo.



$\max_{\lambda_i} (\|h_{\lambda_i} - \mathcal{P}_n h_{\lambda_i}\|^2)$ en función de la dimensión de las bases.

Optimización de hiperparámetros de hp-greedy


- Para hp-greedy: búsqueda de la semilla de la RB global y l_{max} con optimización bayesiana de hiperparámetros.
- Bases hasta 4 veces más chicas sin pérdida de precisión.
- Mejoras de órdenes de magnitud para misma dimensión.



$\max_{\lambda_i} (\|h_{\lambda_i} - \mathcal{P}_n h_{\lambda_i}\|^2)$ en función de la dimensión de las bases.

Elección de regresiones con AutoML


- Optimización del error de regresiones para modelos sustitutos.
- Búsqueda rigurosa de modelos de regresión con AutoML.
- Competencia de +80 pipelines de ML.
- Con Procesos Gaussianos se obtiene indistinguibilidad respecto a NR.




Error de modelos sustitutos provenientes de diferentes métodos de regresión.

Optimización Multi-Objetivo de modelos sustitutos

- Espacio de parámetros 2D.
- Modelos sustitutos de amplitud y fase por separado.
- Búsqueda bayesiana de hiperparámetros de hp-greedy y elección y tuneo de regresiones.
- Optimización multi-objetivo de error y tiempo de inferencia.
- Posibilidad de recorrer Frente de Pareto.




Modelos sustitutos de amplitud.




Modelos sustitutos de fase.

Error medio vs tiempo de predicción de diferentes modelos sustitutos.

Optimización Multi-Objetivo de modelos sustitutos



Incidencia de $l_{\max}$. Modelos de Amplitud.



Incidencia de $l_{\max}$. Modelos de Fase.

	Métrica	Base Reducida	hp-greedy
Modelo sustituto de Amplitud	Error relativo medio	$1,7 \times 10^{-5}$	$2,2 \times 10^{-7}$
	Tiempo predicción medio [ms]	1,6	1,2
Modelo sustituto de Fase	Error relativo medio	$2,0 \times 10^{-6}$	$2,2 \times 10^{-12}$
	Tiempo predicción medio [ms]	1,8	3,7
Modelo sustituto de onda gravitacional	Error relativo medio	$3,2 \times 10^{-2}$	$2,5 \times 10^{-7}$
	Mismatch medio	$1,6 \times 10^{-2}$	$3,6 \times 10^{-8}$
	Tiempo predicción medio [ms]	4,7	8,1
NRHybSur3dq8	Mismatch medio (multimodal) vs NR	1×10^{-5}	
	Tiempo predicción medio [ms]	40	


Conclusiones

Conclusiones

- Se ha optimizado modelos sustitutos que permiten afrontar las mejoras de los detectores de GW.
- Se ha desarrollado la librería modular `scikit-reducedmodel` según los estándares de `scikit-learn`. Está diseñada para crear aproximaciones precisas y rápidas de ondas gravitacionales.
- `scikit-reducedmodel` permite utilizar `hp-greedy` y optimizar las regresiones de los modelos sustitutos.
- Se ha encontrado alta dependencia de los resultados de `hp-greedy` con respecto a sus hiperparámetros.
- *hp-greedy* permite mejores compresiones sin pérdida de precisión.
- Se ha realizado una búsqueda rigurosa de regresiones con AutoML.
- GPR a lo largo de diversos estudios es el mejor modelo de regresión.
- Se ha utilizado optimización bayesiana multi-objetivo para `hp-greedy` y elegir y tunear diversos modelos de regresión.
- Se ha obtenido modelos sustitutos con mismatch de $\sim 10^{-8}$ y tiempos de inferencia ~ 8 ms, utilizando CPU.

Gracias!

Construyendo una Base Reducida.



Proyección ortogonal de una función h_{Λ_3} sobre el span de una base reducida.

Figura esquemática de un modelo sustituto.

